

Machine learning

Classification

Rakotoarimalala Tsinjo Tony

- La classification est une tâche qui nécessite l'utilisation d'algorithmes d'apprentissage automatique qui apprennent à attribuer une étiquette de classe aux exemples du domaine problématique.
- Un exemple facile à comprendre est la classification des courriels comme "*spam*" ou "*non spam*".

- Soit $\mathcal{D} = \{(x_i, y_i)\}_{i=1}^N$ ensemble de données tel que x_i appartient à un espace $\mathcal{X}$ (par exemple $\mathcal{X} = \mathbb{R}^d$) et $y_i \in \mathcal{Y}$ l'étiquette associée à x_i ($\mathcal{Y}$ étant un ensemble fini).

Les différents types de problème de classification dépendent de la taille de $\mathcal{Y}$:

- **classification binaire** si $|\mathcal{Y}| = 2$ (ex: $\mathcal{Y} = \{-1, 1\}$ ou $\mathcal{Y} = \{0, 1\}$).
Applications : Détection de fraudes, détection d'anomalies, Spam ou pas, ...
- **classification multi-classe** si $\mathcal{Y} = \{1, 2, \dots, K\}$
Applications : reconnaissance d'objets, d'écriture
- **classification multi-étiquettes** si $\mathcal{Y} = 2^{\{1, 2, \dots, K\}}$
Applications: Reconnaissance du topics de documents

On cherche à apprendre une fonction de classification $f: \mathcal{X} \rightarrow \mathcal{Y}$ permettant de prédire le label de x .

Classification binaire

La classification binaire fait référence aux tâches de classification en deux étiquettes de classe.

En voici quelques exemples :

- Détection de spam par email (spam ou non).
- Prédiction de désabonnement (désabonnement ou non).
- Prédiction de la conversion (achat ou non).

La classification binaire fait référence aux tâches de classification en deux étiquettes de classe.

En voici quelques exemples :

- Détection de spam par email (spam ou non).
- Prédiction de désabonnement (désabonnement ou non).
- Prédiction de la conversion (achat ou non).

En général, les tâches de classification binaire impliquent une classe qui représente l'état normal et une autre classe qui représente l'état anormal.

Exemple

Jour	Attributs des exemples				Classe
	Prévisions	Température	Humidité	Vent	
1	Ensoleillé	Chaud	Élevée	Faible	Non
2	Ensoleillé	Chaud	Élevée	Fort	Non
3	Nuageux	Chaud	Élevée	Faible	Oui
4	Pluvieux	Moyen	Élevée	Faible	Oui
5	Pluvieux	Frais	Normale	Faible	Oui
6	Pluvieux	Frais	Normale	Fort	Non
7	Nuageux	Frais	Normale	Fort	Oui
8	Ensoleillé	Moyen	Élevée	Faible	Non
9	Ensoleillé	Frais	Normale	Faible	Oui
10	Pluvieux	Moyen	Normale	Faible	Oui
11	Ensoleillé	Moyen	Normale	Fort	Oui
12	Nuageux	Moyen	Élevée	Fort	Oui
13	Nuageux	Chaud	Normale	Faible	Oui
14	Pluvieux	Moyen	Élevée	Fort	Non


Ensemble d'exemples pour playTennis

Exemple

- On veut représenter donc la connaissance quand-est-ce qu'on peut jouer?
- On a une classification binaire avec les classes possibles sont **OUI** et **NON**
- Les individus sont des vecteurs de 4 valeurs

Arbre de décision

- Étant donnée plusieurs caractéristiques (variable), la décision se commence par un de ces caractéristiques; si ce n'ai pas suffisant, on utilise une autre, ainsi de suite.
- Exemple de construction d'un arbre de décision pour notre exemple



Construction d'un arbre de décision

L'algorithme général de création d'un arbre de décision:

- ❶ Déterminer la meilleure caractéristique dans l'ensemble de données d'entraînement.
- ❷ Diviser les données d'entraînement en sous-ensembles contenant les valeurs possibles de la meilleure caractéristique.
- ❸ Générez de manière récursive de nouveaux arbres de décision en utilisant les sous-ensembles de données créés.
- ❹ Lorsqu'on ne peut plus classifier les données, on s'arrête.

- ID3 est un algorithme de création d'un arbre de décision.
- L'algorithme général définit ci-dessus reste vrai.
- Il nous reste à expliquer la façon comment ID3 fait pour choisir la meilleure caractéristique/variable pour l'utiliser pour créer un nœud dans l'arbre selon cette variable

- On appelle entropie d'un ensemble d'individu S

$$\text{Entropie}(S) = \sum_{c \in \text{classes}(S)} -p_c \times \log_2(p_c)$$

- Pour notre exemple, au début S étant l'ensemble des 14 individus donc

$$\text{Entropie}(S) = -\left(\frac{9}{14}\right) \times \log_2\left(\frac{9}{14}\right) - \left(\frac{5}{14}\right) \times \log_2\left(\frac{5}{14}\right) = 0.94$$

- S'il n'y qu'une seule classe dans S alors

$$\text{Entropie}(S) = 0$$

Interprétation de l'entropie

- L'entropie est appelée aussi **mesure d'incertitude**
- Plus l'incertitude est élevée, plus les données sont mélangées (hétérogènes) c'est-à-dire il y a mélange dans les classes
- L'incertitude atteint son maximum si les proportions de chaque classe dans les données sont les mêmes

Définition

- On définit le gain d'information d'une variable/caractéristique A sur l'ensemble des individus S :

$$\text{Gain}(S, A) = \text{Entropie}(S) - \sum_{v \in \text{valeurs}(A)} \frac{|S_v|}{|S|} \times \text{Entropie}(S_v)$$

avec $|S_v|$ le nombre des données dans S ayant pour classe v et $|S|$ le nombre de données dans S

- Pour notre exemple, si on prend $A = \text{"Prévisions"}$

temps	jouer(oui)	jouer(non)	S_v	Entropie(S_v)
ensoleillé	2	3	5/11	$\left(-\frac{3}{5} \times \log_2\left(\frac{3}{5}\right) - \frac{2}{5} \times \log_2\left(\frac{2}{5}\right)\right)$
nuageux	4	0	4/11	$\left(-\frac{0}{4} \times \log_2\left(\frac{0}{4}\right) - \frac{4}{4} \times \log_2\left(\frac{4}{4}\right)\right)$
pluvieux	3	2	5/11	$\left(-\frac{3}{5} \times \log_2\left(\frac{3}{5}\right) - \frac{2}{5} \times \log_2\left(\frac{2}{5}\right)\right)$

Donc

$$\text{Gain}(S, A) = 0.94 - 0.357 \times (0.97) - 0.286 \times (0) - 0.357 \times (0.97) = 0.24742$$

Interprétation du gain d'information

- Le gain d'information est la différence entre l'entropie avant et après une division d'un ensemble de données selon un caractère/variable
- Dans la formule, $H(S)$ est l'entropie avant la division, et la deuxième partie n'est rien d'autre que l'entropie après la division (entropie restante: somme pondérée des entropies de chaque partie de la division)
- Gain d'information élevé $\Rightarrow$ réduction de l'incertitude/entropie restante $\Rightarrow$ sous ensembles plus homogènes
- **Choisir la variable/caractéristique qui permet le plus grand gain d'information pour diviser l'ensemble de données**

Choix de la meilleure variable

- On fait les mêmes calculs pour chaque variable
- On obtient alors

	Prévisions	température	humidité	vent
Gain	0.247	0.029	0.152	0.048

- On choisit alors **Prévisions** comme variables pour le premier nœud
- On refait comme le l'algorithme général l'indique

Algorithme CART

- **CART** s'inspire de l'algorithme général de construction d'arbre de décision
- Pour choisir la meilleure caractéristique pour la division, il s'appuie sur l'impureté de Gini définie par:

$$\text{Gini}(S) = 1 - \sum_{i=1}^k (p(c_i))^2$$

où c_i avec $i = 1, 2 \dots k$ sont les classes et $p(c_i)$ la probabilité qu'une donnée appartient à la classe c_i (proportion des données ayant la classe c_i)

- L'impureté de Gini restante après division à partir d'un caractèreistique/variable A est défini par

$$\text{Gini}_A = \sum_{v \in \text{valeurs}(A)} \frac{|S_v|}{|S|} \times \text{Gini}(S_v)$$

avec $|S_v|$ le nombre des données dans S ayant pour classe v et $|S|$ le nombre de données dans S

Interprétation de l'indice d'impureté de Gini

- Plus cette indice d'impureté est petite, plus les données sont homogènes (appartiennent à la même classe)
- **Sélectionnez la caractéristique qui minimise l'impureté après division**